Prepoznavanje zdravstvenog stanja pčela na osnovu fotografije

Transfer learning, poređenje MobileNetV3 / ResNet50 / EfficientNetB0
i integracija u informacioni sistem „Košnica“

Medžid Jašarović · konsultacije — ML deo rada

Šta je urađeno — pregled

- **Pregled 5 javnih skupova** slika pčela — klase i pogodnost
- **Prvi eksperiment (BeeImage):** 97% tačnosti, ali model ne prepoznaje bolest — otkriveno i dokazano
- **Glavni eksperiment (VarroaDataset):** 3 arhitekture, isti uslovi, metrike + matrice konfuzije
- **Provera da model gleda grinju** — ne samo tačnost
- **Test van skupa za trening** — druga kamera i terenske fotografije
- **Izabran ResNet50**, integrisan u sistem preko Python/FastAPI servisa

Izabrani model na test skupu
(snimci koje model nikad nije video):

93,1%

tačnost · F1 0,913 · AUC 0,975

Pregled javnih skupova podataka

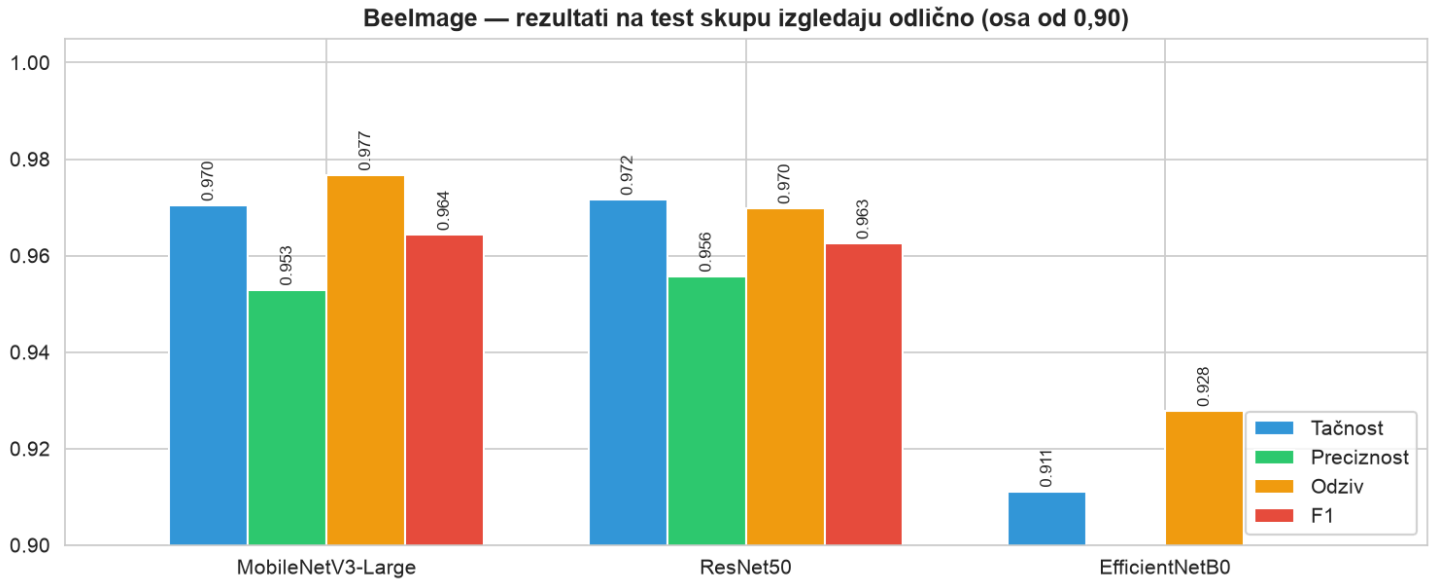
Ključni uslov: oznaka mora opisivati pčelu na slici

Skup	Slika	Klase	Oznaka po pčeli	Ista pozadina	Podela po snimku
BeeImage (Kaggle)	5.172	6 stanja košnice	✗ po snimku	✗	✗
VarroaDataset (TU Wien)	13.509	zdrava / varoa	✓ **+ označena grinja**	✓	✓ **zvanična**
BeeDataset (BeeAlarmed)	7.490	varoa, polen, osa, hlađenje	✓	✓	✗
Bilik i sar. 2021	600	pčela, grinja	✓	✗	detekcija objekata
Roboflow Universe	razno	grinja, pčela	✓	✗	detekcija objekata

→ **VarroaDataset** za trening, **BeeDataset** kao nezavisan test. BeeImage je korišćen prvi — i pokazao zašto su ovi uslovi bitni.

Prvi eksperiment: BeeImage

Odlični rezultati na test skupu …



Najbolji model (MobileNetV3):

97,0%

tačnosti na 776 test slika

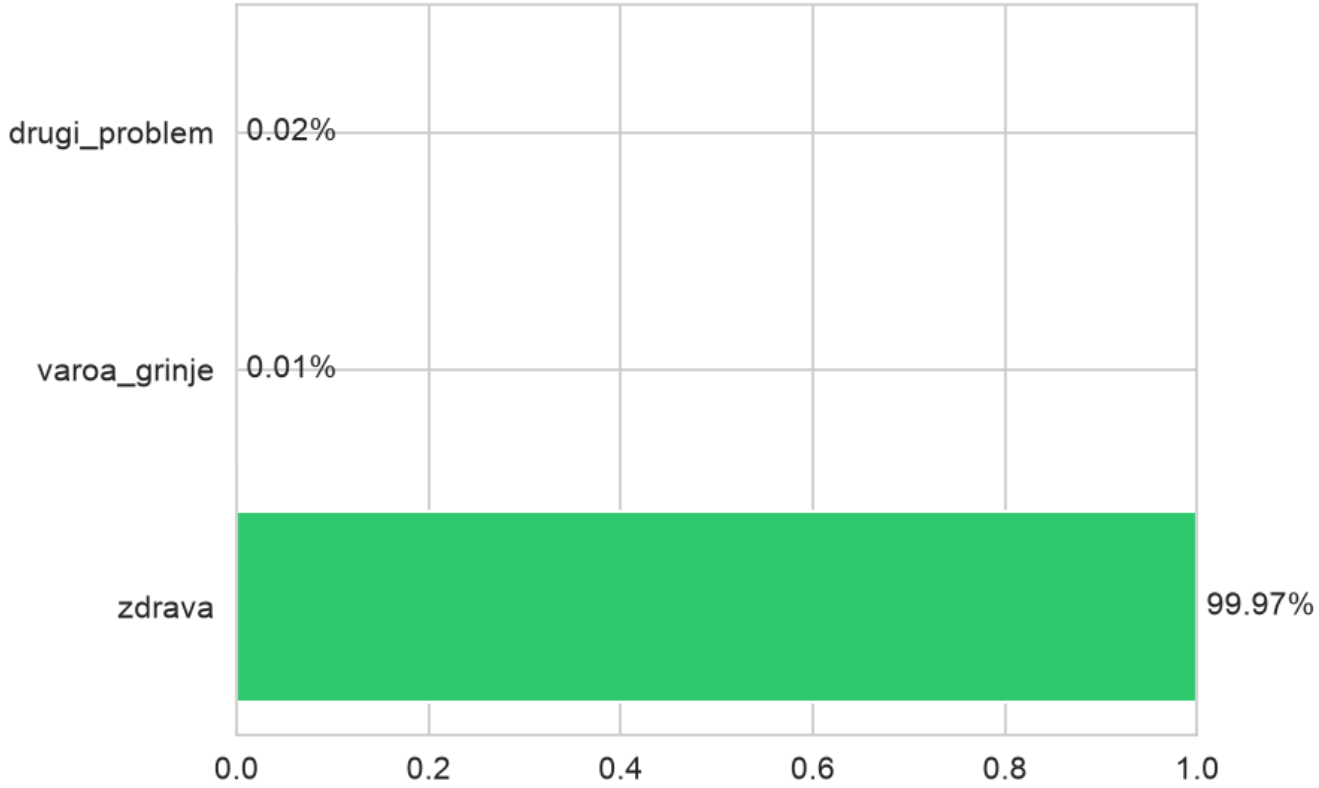
… ali ručni test u aplikaciji

Pčela sa dve jasno vidljive grinje

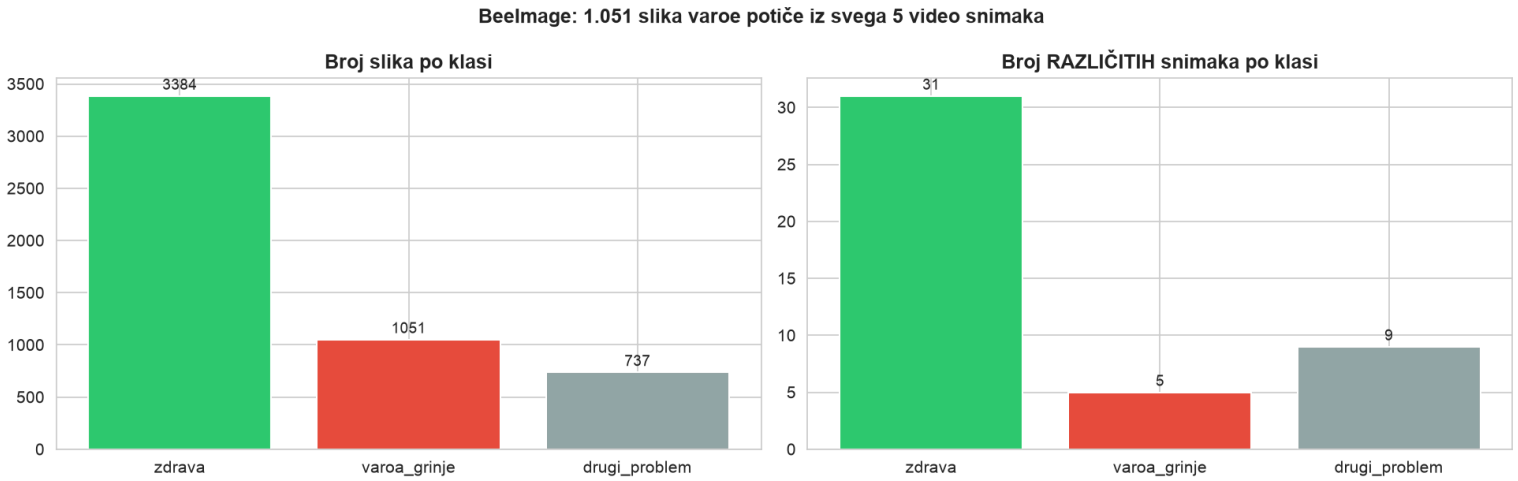
Dve grinje jasno vidljive

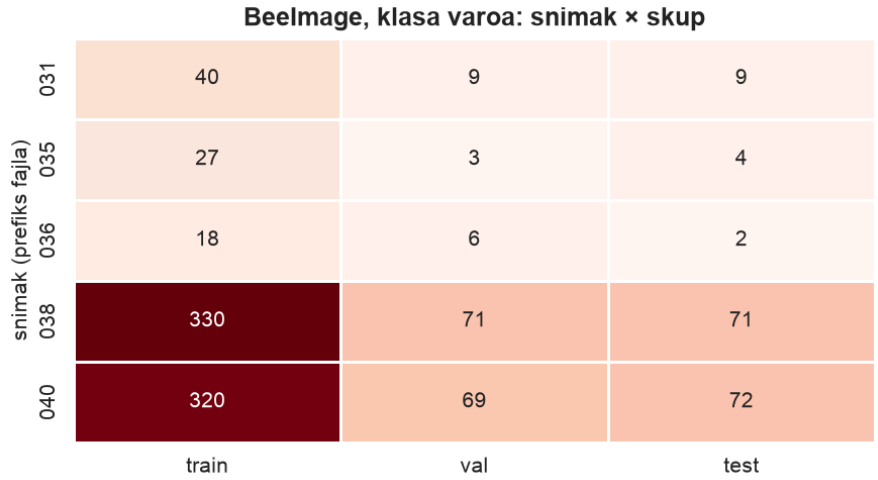


BeeImage model: „zdrava“



Zašto? Oznaka opisuje snimak, ne pčelu

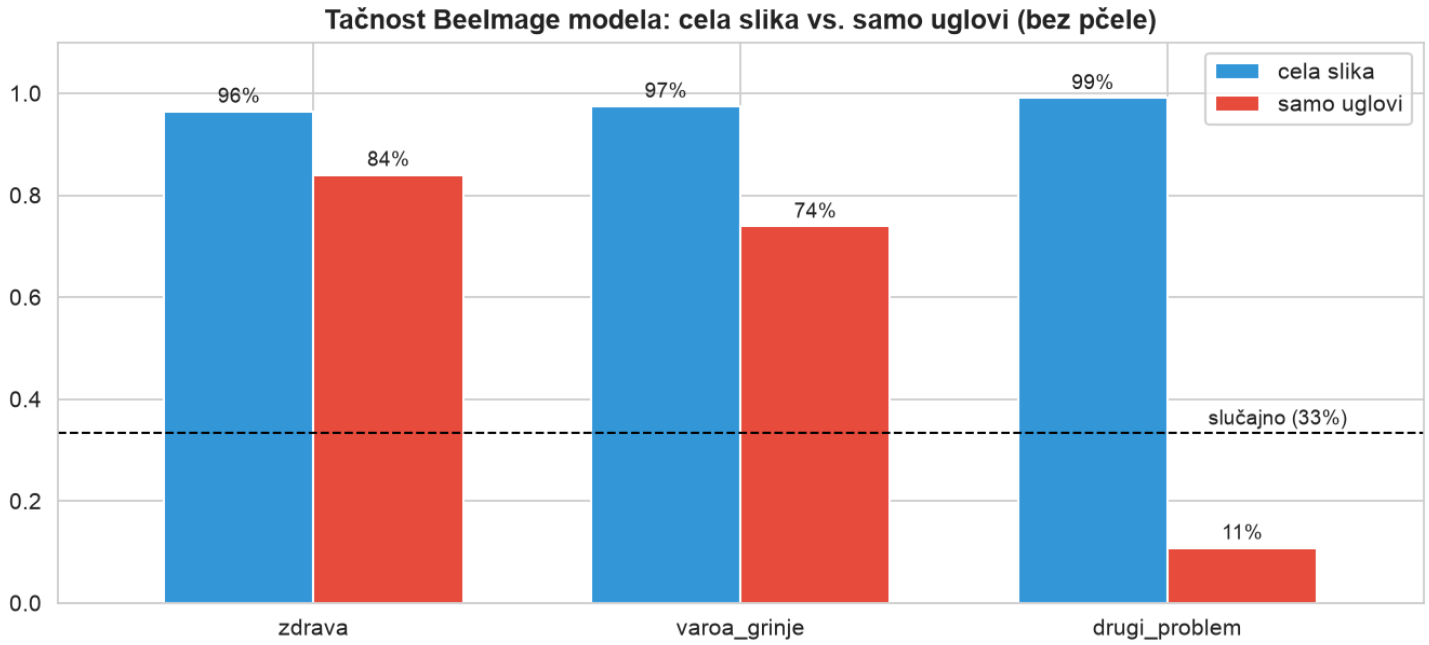




- pčele su isečene iz **video snimaka**; svaka dobija oznaku cele košnice
- 1.051 slika varoe = **5 snimaka** (89% iz dva)
- nasumična podela → **isti snimak u trening i u test** skupu
- grinja se na isečcima (~61×61 px) uglavnom ne vidi

Dokaz: test prečice

Model dobija samo uglove slike — bez pčele



Iz komadića pozadine model „prepoznaje“ varou u

74%

slučajeva. Slučajno bi bilo 33%.

Model je naučio **pozadinu snimka** — *shortcut learning*. Tačnost od 97% meri prepoznavanje snimka, ne bolesti.

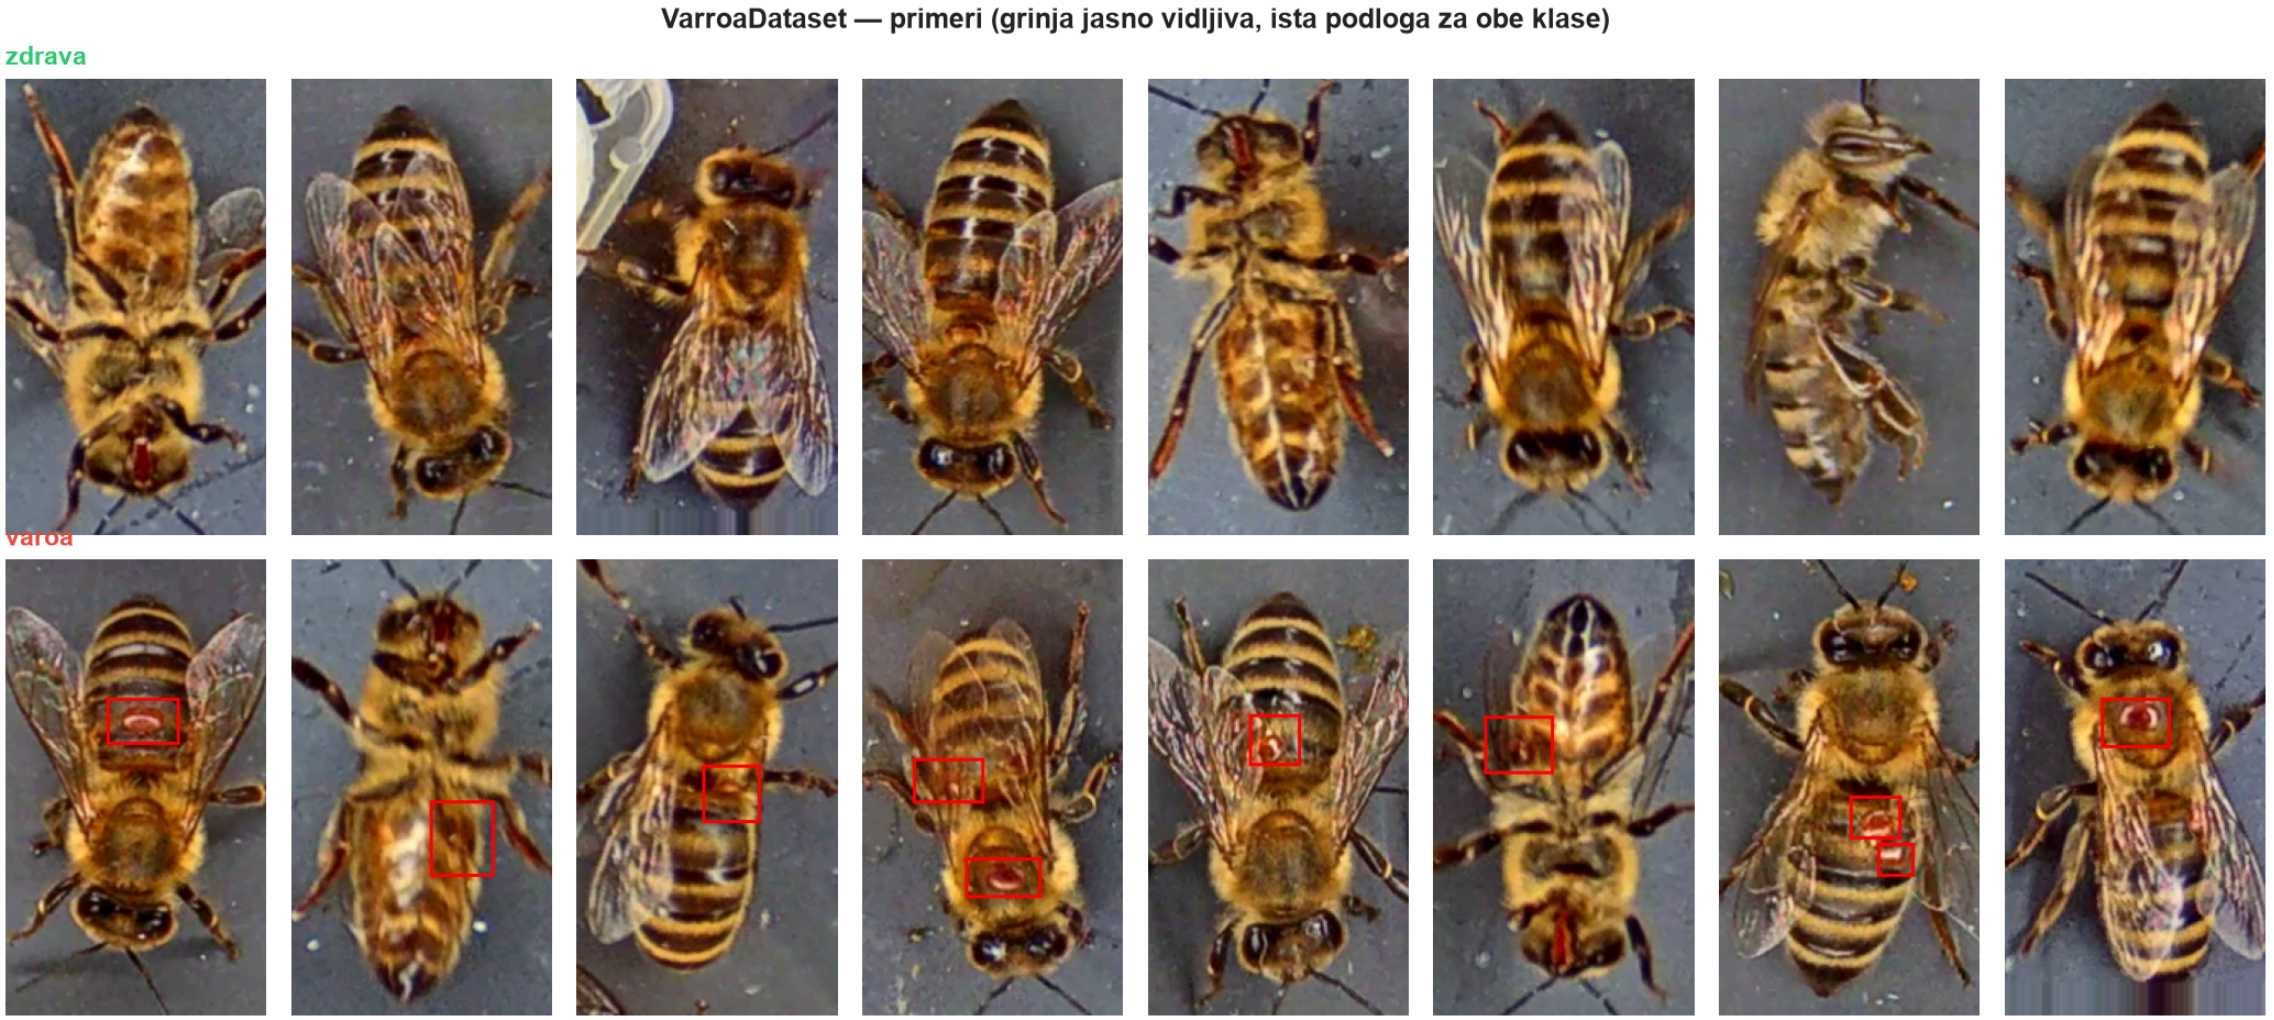
Pouke → uslovi za novi skup podataka

1. **Oznaka po pčeli**, na osnovu vidljivog obeležja
2. **Ista pozadina** za sve klase
3. **Podela po snimku** — test sadrži snimke koje model nije video
4. Visoka tačnost nije dovoljna — treba **proveriti šta model gleda** i testirati ga na slikama drugačijeg porekla

Sva četiri uslova su ugrađena u glavni eksperiment.

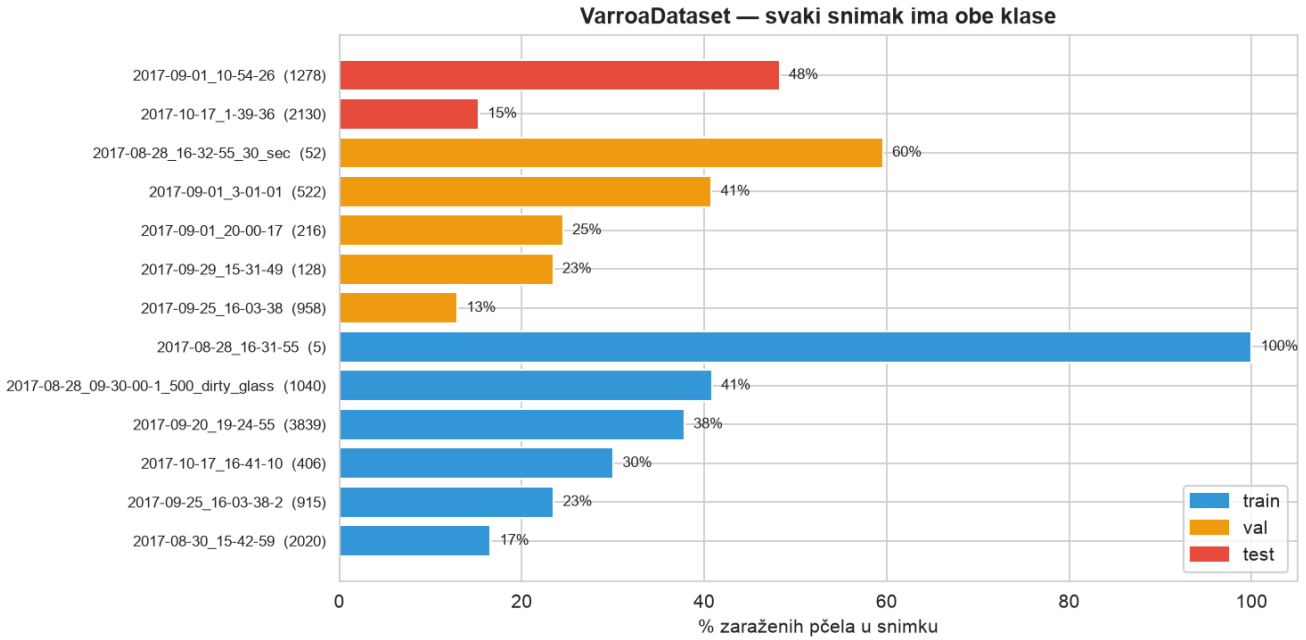
VarroaDataset (TU Wien, 2020)

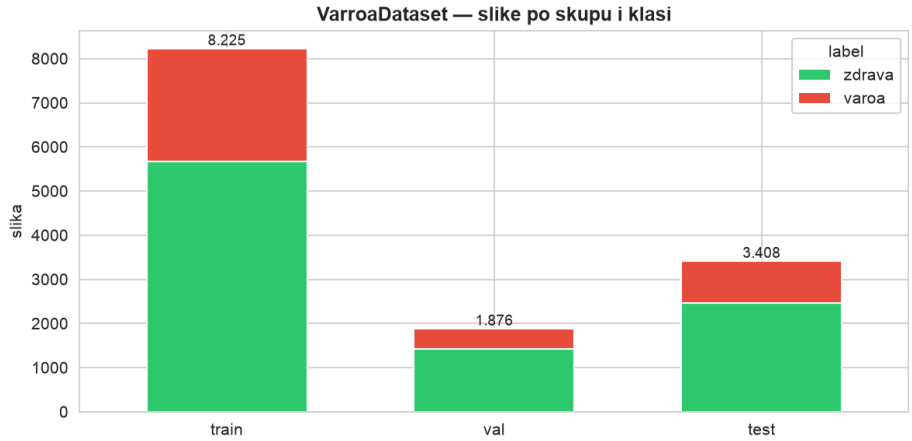
13.509 slika pojedinačnih pčela · svaka grinja ručno označena · CC BY 4.0



VarroaDataset — poštena podela

Svaki snimak ima i zdrave i zaražene pčele; nijedan snimak nije u dva skupa





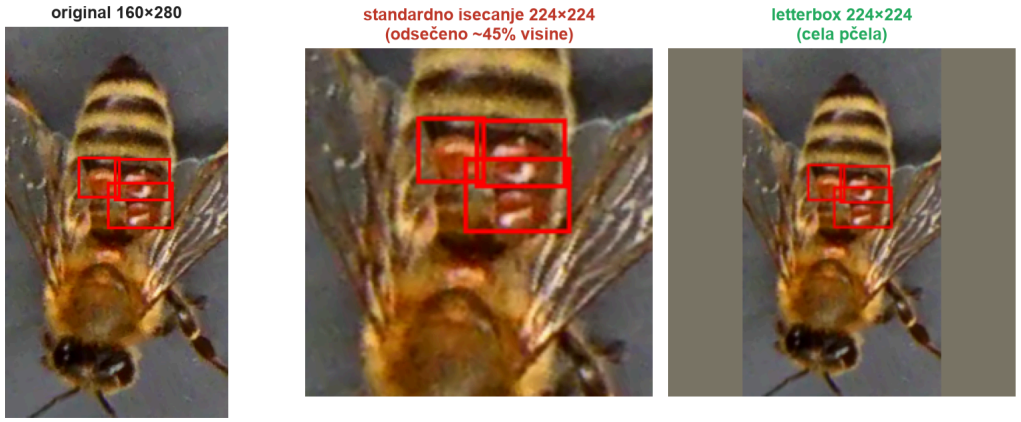
Klase: zdrava (9.562) i varoa (3.947). Oznaka 3 (grinja delimično skrivena) računa se kao varoa, kao kod autora.

Transfer learning — postupak

Isti za sve tri arhitekture (PyTorch + torchvision)

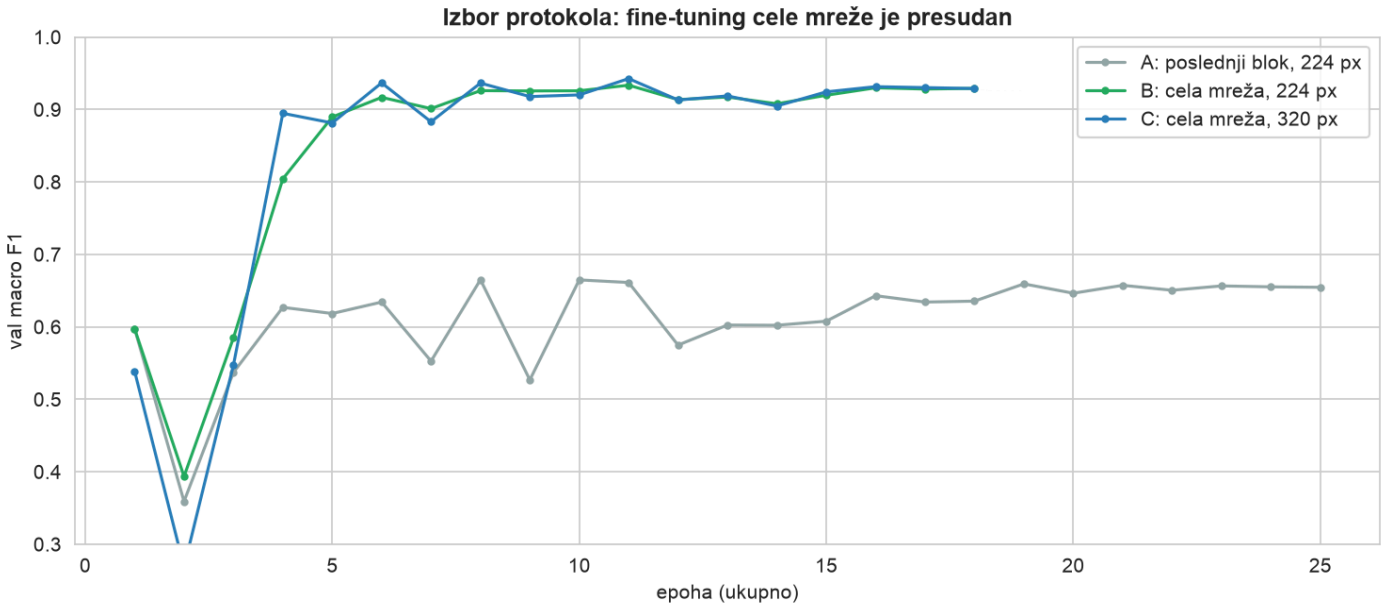
1. mreža istrenirana na **ImageNet**-u (1,28 mil. slika)
2. poslednji sloj (1.000 klasa) → novi sa **2 izlaza**: zdrava, varoa
3. **faza 1:** telo zamrznuto, trenira se samo glava — 3 epohe, lr 10^{-3}
4. **faza 2:** fine-tuning **cele mreže** — 15 epoha, lr 10^{-4}
5. checkpoint sa najboljim **macro F1 na validacionom** skupu
6. **test skup** se koristi tačno jednom, na kraju

Isti za sve: podaci, priprema slike, augmentacija, batch 32, AdamW, težine klasa, seme 42.



Letterbox umesto isecanja — ne odseca glavu i zadak, gde je grinja često.

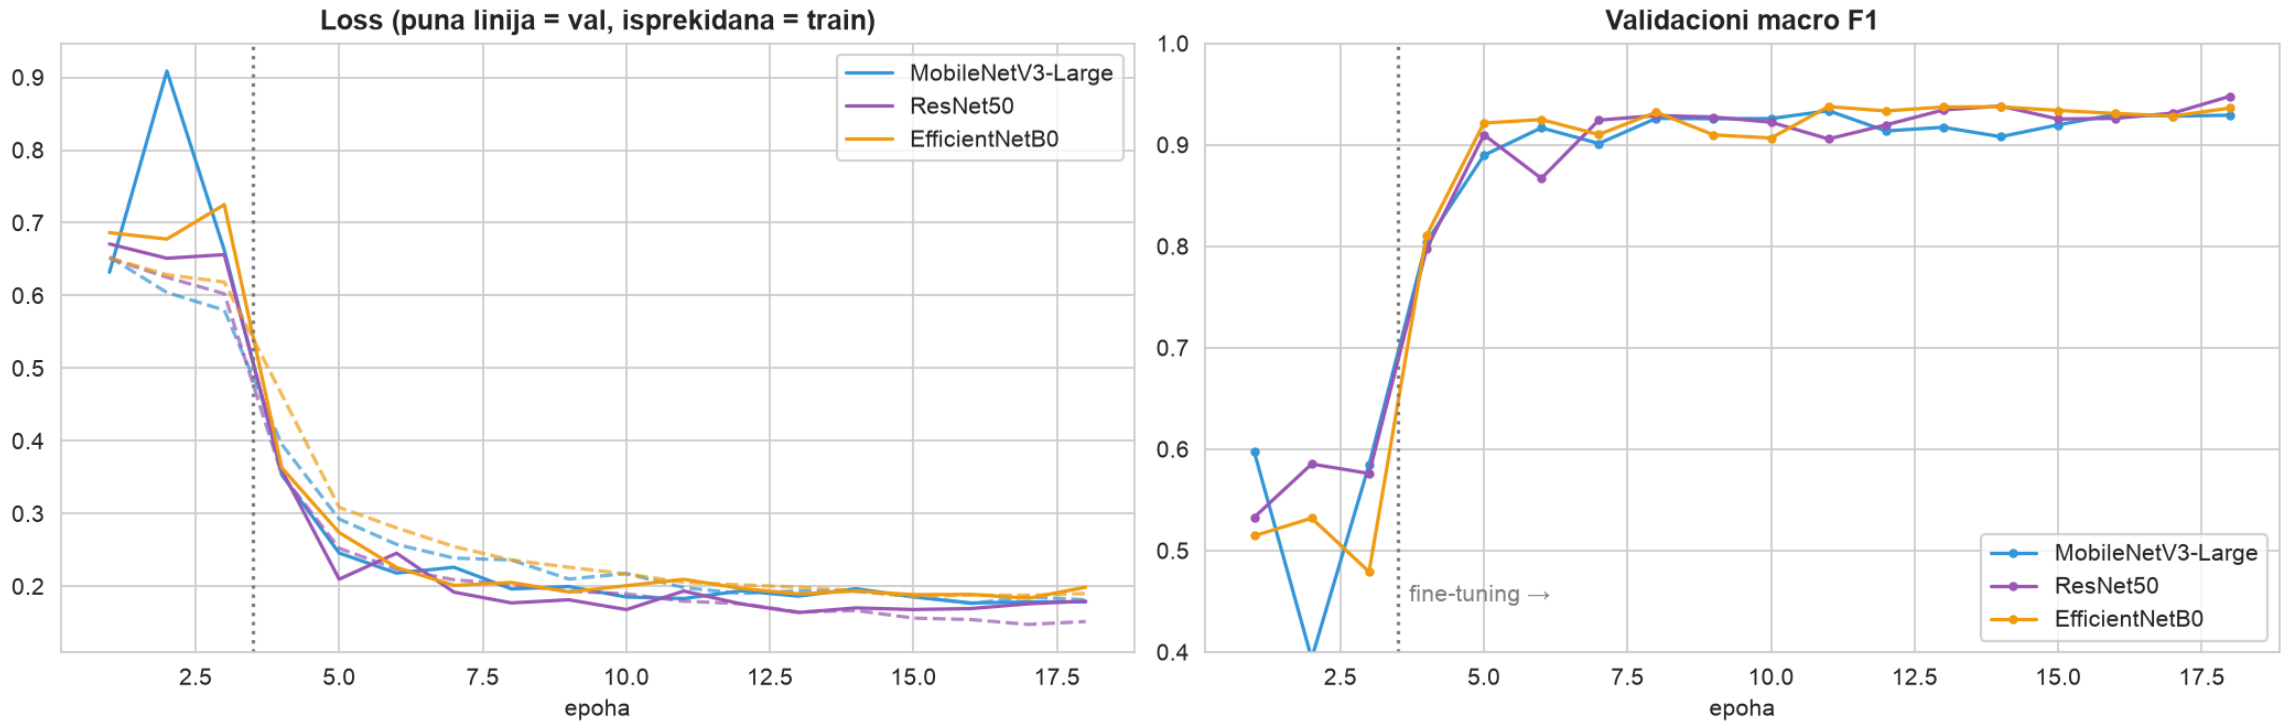
Izbor protokola — samo na validacionom skupu



- **A** — protokol iz Beelmage-a (samo poslednji blok): val F1 **0,665** — model ne uči grinju
- **B** — cela mreža: **0,934**
- **C** — cela mreža, veća slika: 0,943, ali 4,7× sporije

Izabrano **B**. Test skup nije korišćen za ovu odluku.

Krive učenja — sve tri arhitekture

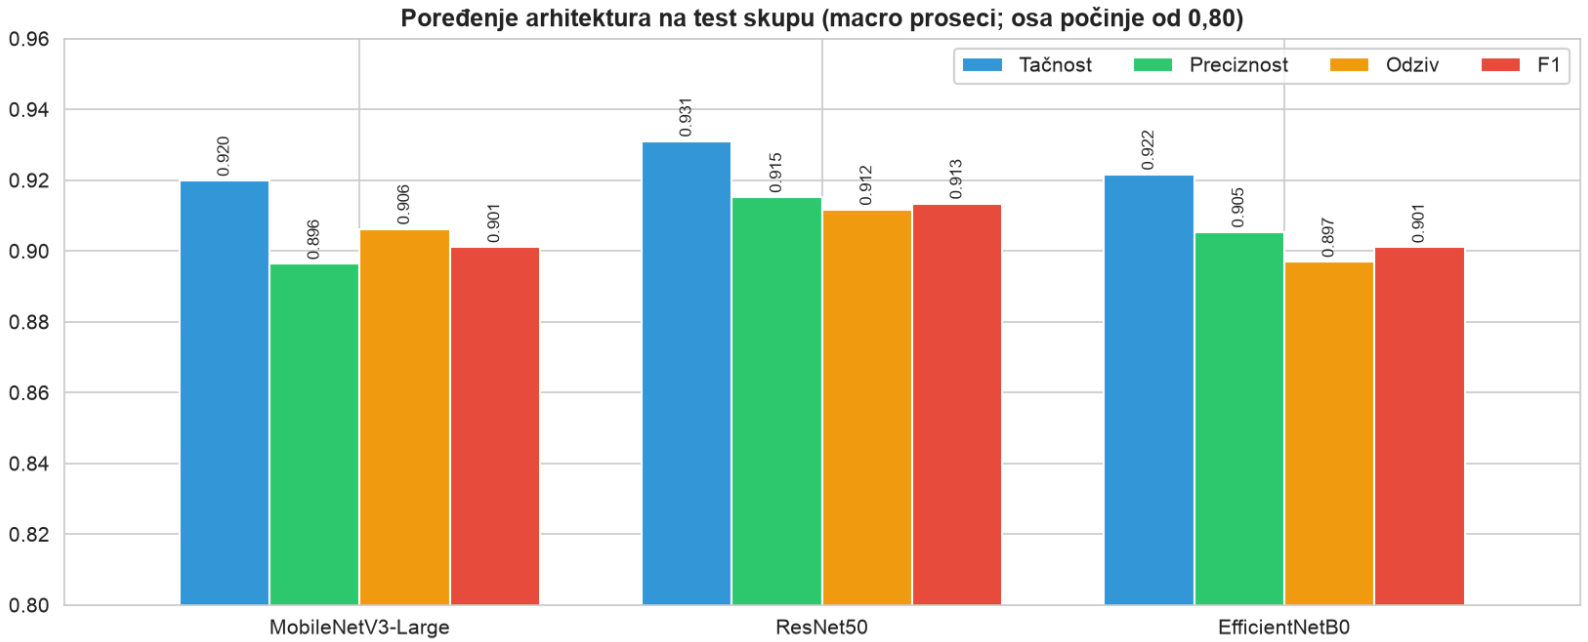


Val loss prati train loss — nema izraženog preprilagođavanja. Isprekidana linija: prelaz u fine-tuning.

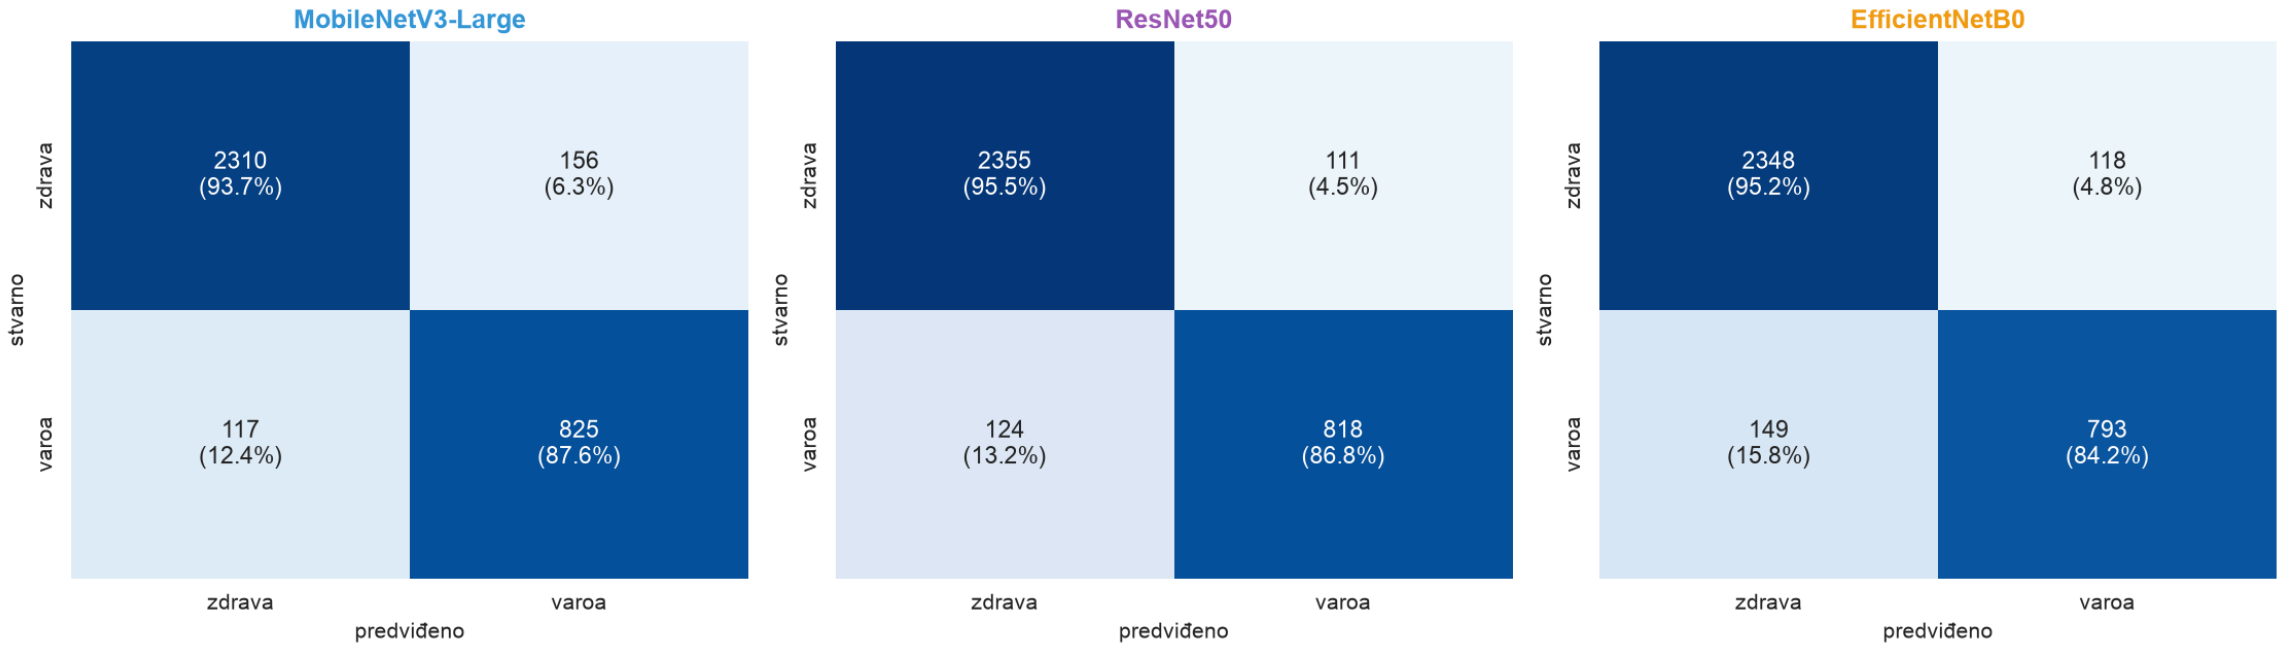
Rezultati na test skupu

3.408 slika iz 2 snimka koje modeli nikad nisu videli

Model	Tačnost	Preciznost	Odziv	F1	Odziv (varoa)	ROC AUC
MobileNetV3-Large	0,920	0,896	0,906	0,901	**0,876**	0,966
ResNet50	**0,931**	**0,915**	**0,912**	**0,913**	0,868	**0,975**
EfficientNetB0	0,922	0,905	0,897	0,901	0,842	0,964

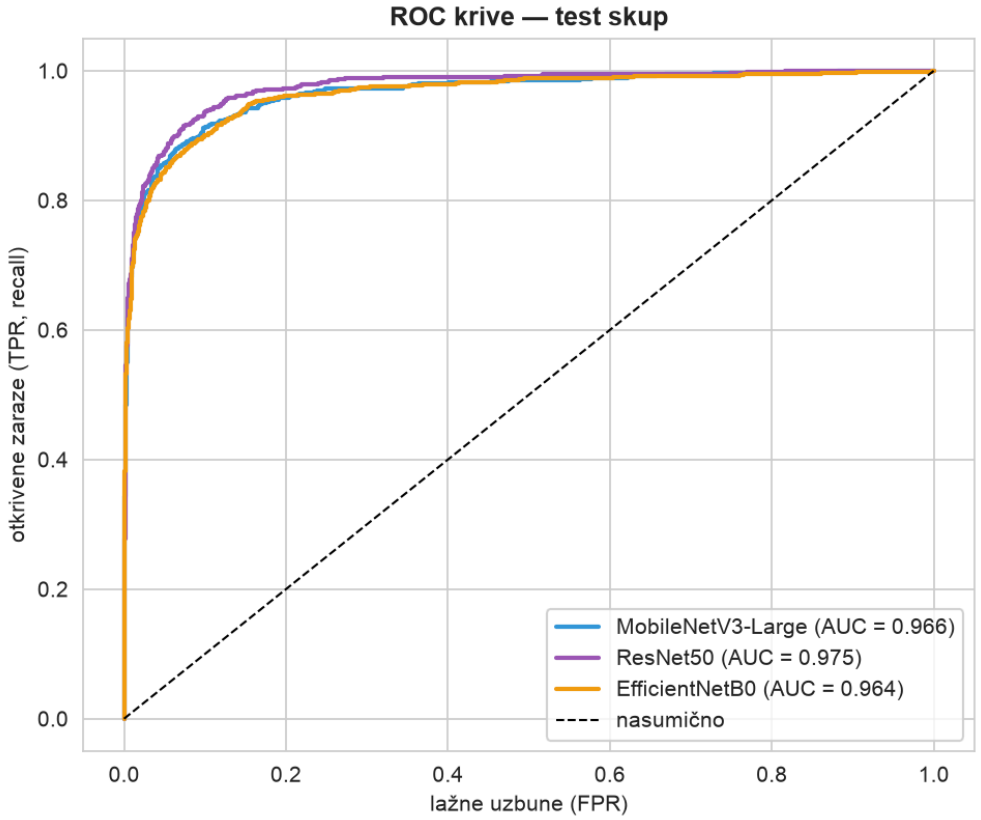


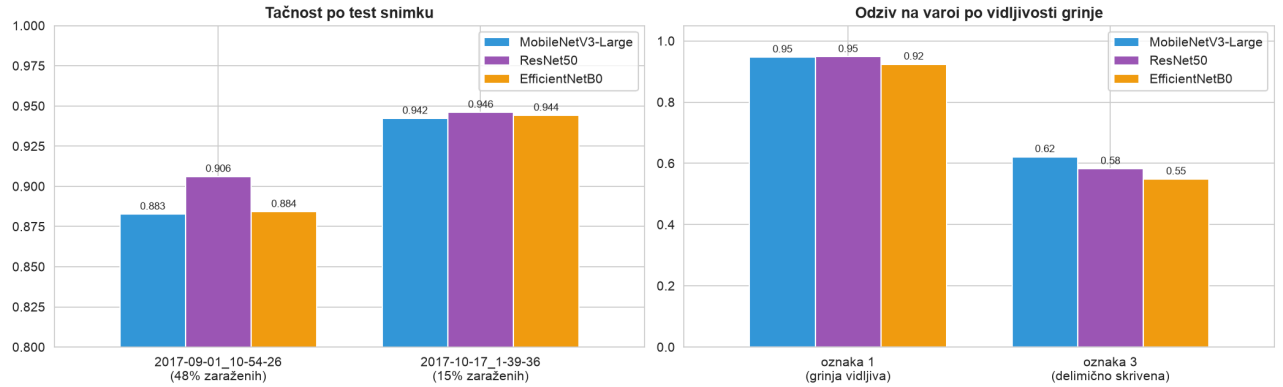
Matrice konfuzije



Donji levi kvadrat = **propuštene zaraze**, gornji desni = **lažne uzbune**. ResNet50: najmanje lažnih uzbuna (111 naspram 156 kod MobileNetV3).

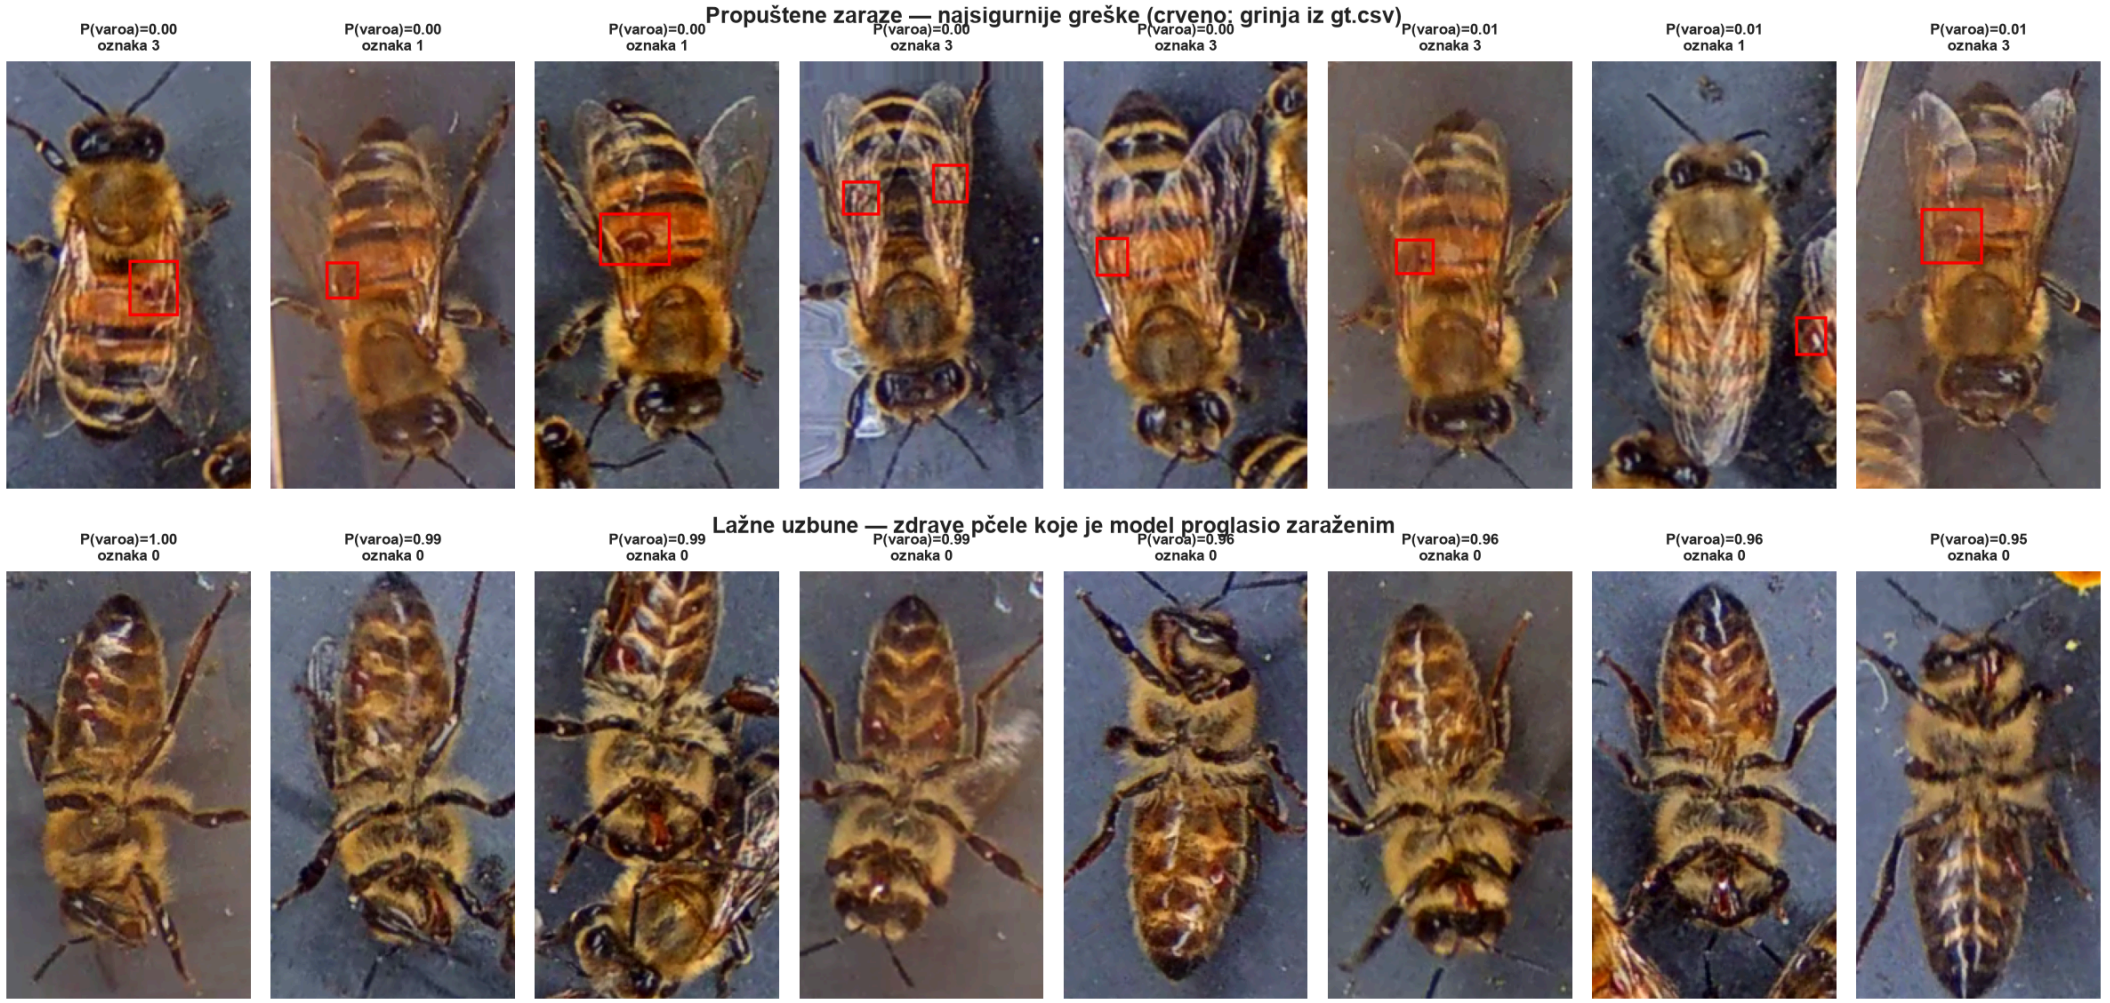
ROC krive i analiza grešaka





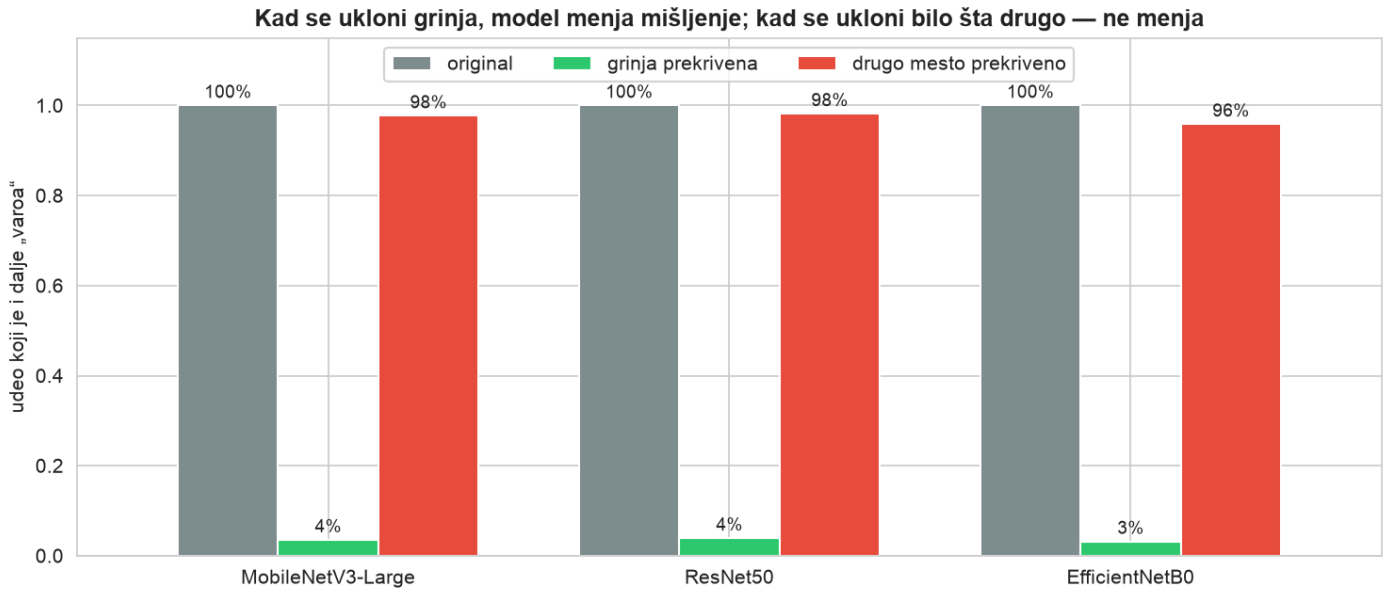
Jasno vidljiva grinja: ~93–95% pronađeno. Delimično skrivena (oznaka 3): ~55–62% — najveći izvor grešaka.

Gde model greši (ResNet50)



Propuštene: grinja ispod krila ili sa strane. Lažne uzbune: odsjaji, polen i tamna mesta koja liče na grinju.

Da li model gleda grinju? Test brisanja grinje



Na zaraženoj pčeli grinja se **prekrije bojom okoline**:

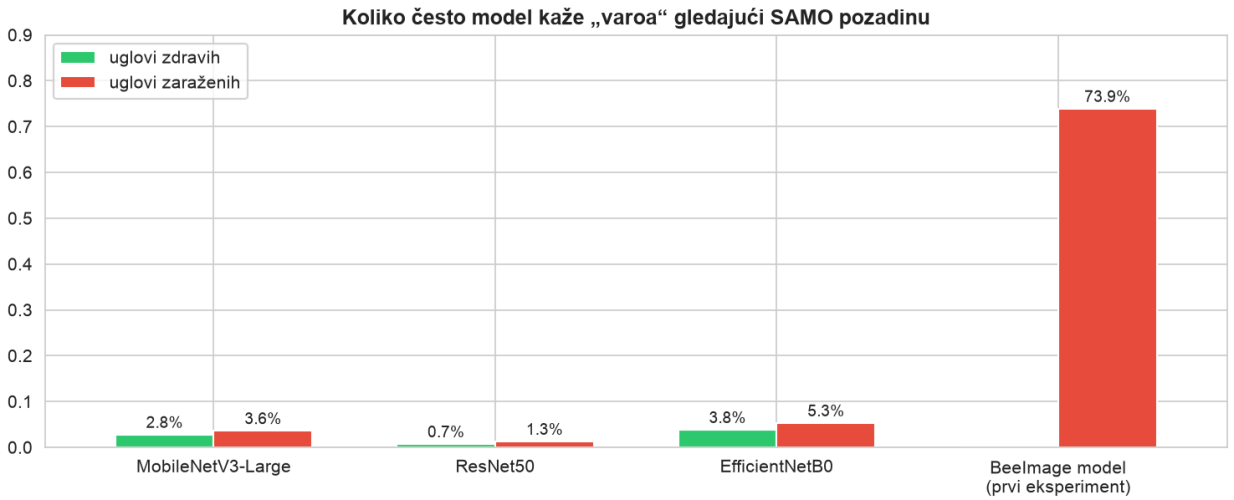
- grinja prekrivena → „varoa“ ostaje kod **3,9%**
- drugo mesto prekriveno (kontrola) → **98,2%**

Odluka sva tri modela **zavisi od grinje** — uzročni dokaz.

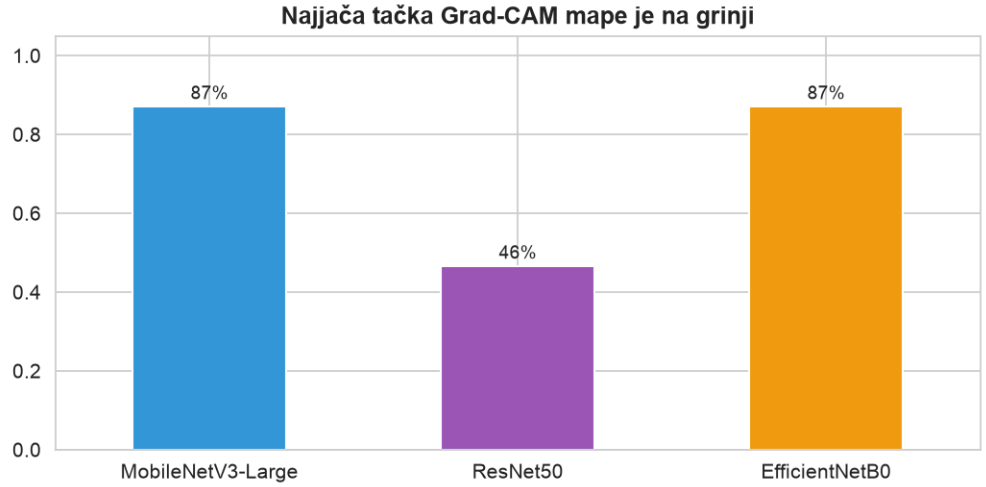
Primeri: šta se desi kad se grinja prekrije (ResNet50)



Samo pozadina · Grad-CAM



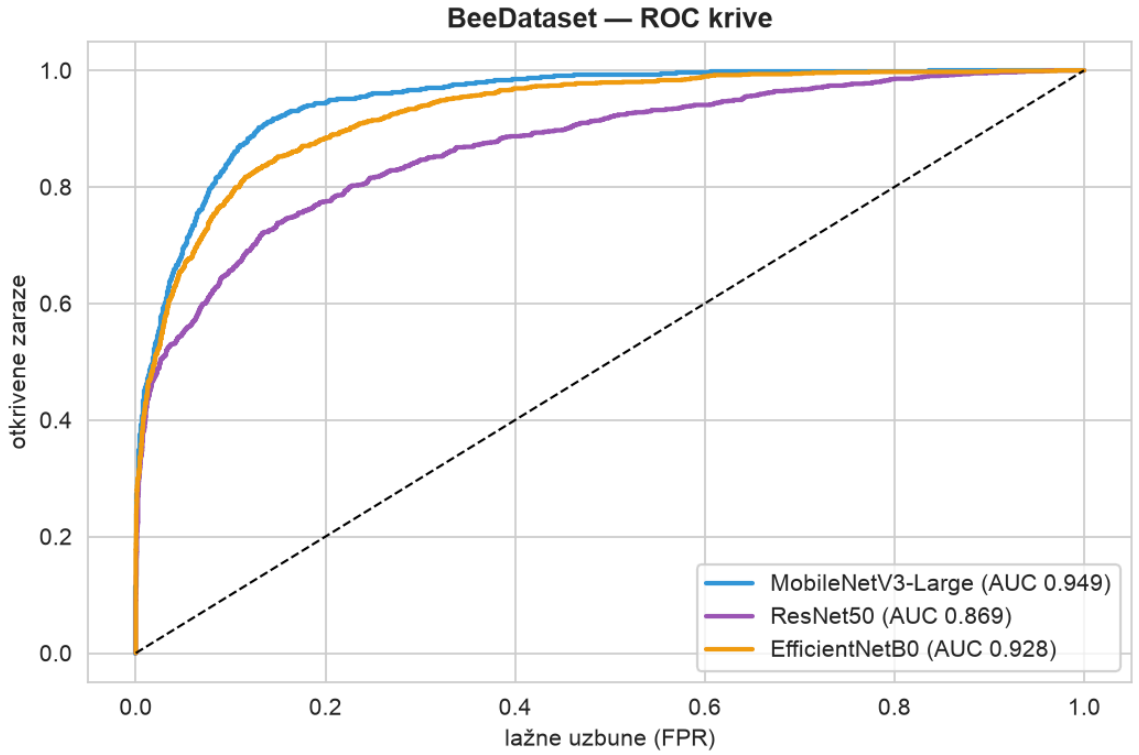
Iz pozadine novi modeli kažu „varoa“ u 1–5% slučajeva — podjednako za zdrave i zaražene. BeeImage model: 74%.

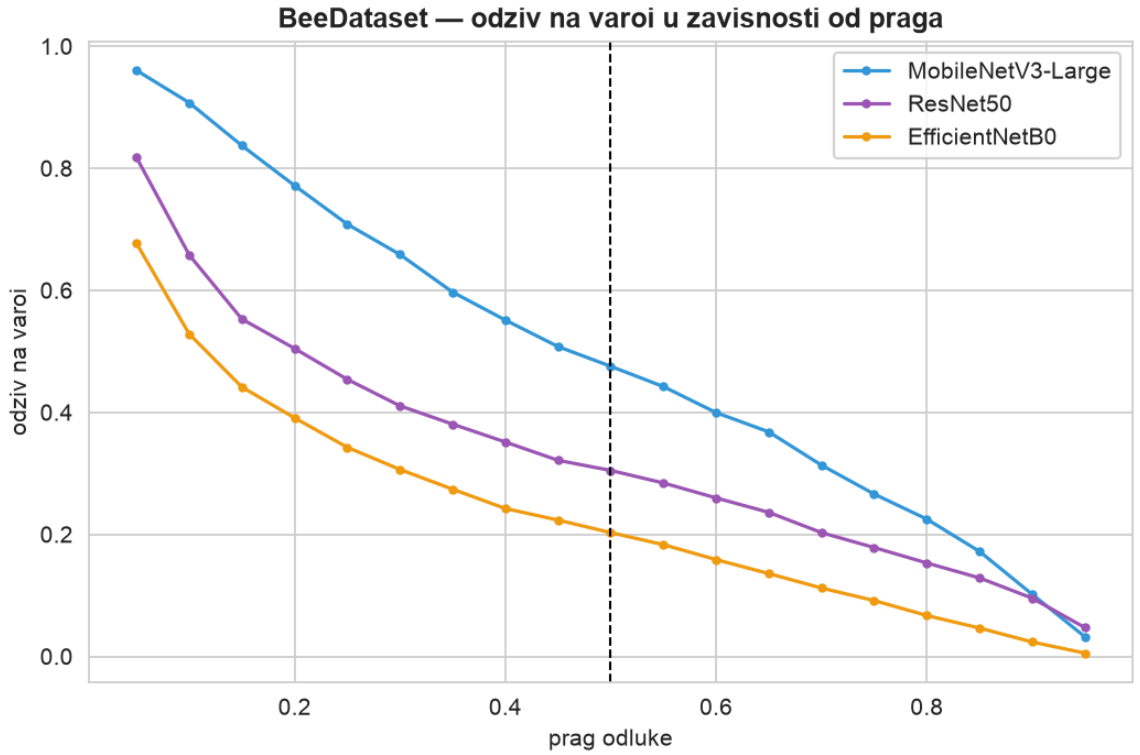


Grad-CAM: najjača tačka mape pažnje pada na grinju (MobileNetV3, EfficientNetB0: 87%). ResNet50 ima širu mapu — ali test brisanja je presudan.

Test van skupa: BeeDataset

Druga kamera, druga zemlja, zelena podloga — 7.490 slika koje model nije video





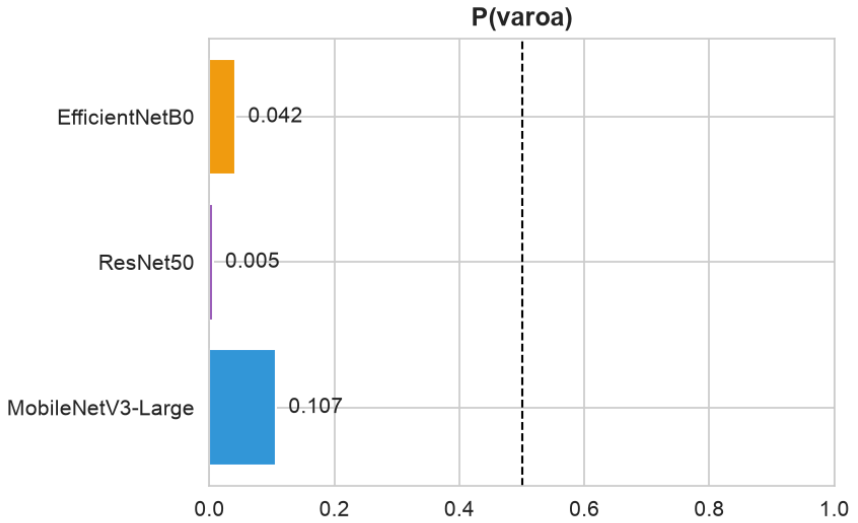
Modeli dobro **razdvajaju** klase (AUC 0,869–0,949), ali su **previše oprezni** na pragu 0,5 — niži prag odluke povećava odziv bez ponovnog treninga.

Terenske fotografije

Fotografija koja je oborila BeeImage model

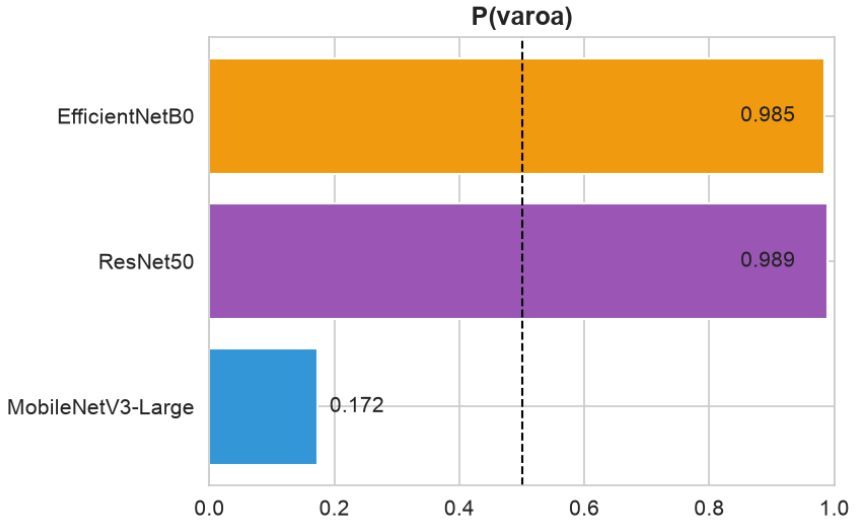
prava klasa: zdrava





prava klasa: varoa





Izbor modela: ResNet50

Svi kriterijumi izbora (zeleno = najbolji u koloni)

	Test F1	Test tačnost	Test odziv (varoa)	Test AUC	Gleda grinju (1 – ostalo posle brisanja)	BeeDataset AUC	ONNX ms / slika	Fajl MB
MobileNetV3-Large	0.901	0.92	0.876	0.966	0.965	0.949	2.59	17.1
ResNet50	0.913	0.931	0.868	0.975	0.961	0.869	11.94	94.2
EfficientNetB0	0.901	0.922	0.842	0.964	0.968	0.928	4.5	16.6

- najbolji po **tačnosti, preciznosti, odzivu, F1** i AUC
- najmanje lažnih uzbuna
- prolazi test brisanja grinje; tačan na terenskoj fotografiji

- razlike ~1 p.p. (jedno seme)
- MobileNetV3 bolji na BeeDataset-u i 4,6× brži — bolji za mobilni uređaj
- zamena modela u sistemu = zamena jednog fajla

BeeImage model vs. novi model

	BeeImage (MobileNetV3)	VarroaDataset (ResNet50)
Tačnost na svom test skupu	97,0%	93,1%
Test skup	isti snimci kao trening	**snimci koje model nije video**
Iz same pozadine kaže „varoa“	74%	**~1%**
Grinja prekrivena → i dalje „varoa“	—	**3,9%**
Fotografija sa dve grinje	„zdrava“ 99,97%	**„varoa“ 98,9%**

Niža tačnost na papiru — ali **poštena**: meri prepoznavanje grinje na novim snimcima.

Integracija u sistem „Košnica“

Model radi u zasebnom Python servisu; backend mu šalje sliku preko HTTP-a

Angular
tab „Zdravlje pčela“
`FormData` + JWT
POST /api/hives/{id}/health-checks

→

ASP.NET Core
BeeHealthChecksController
provera vlasništva nad košnicom
`HttpClient` → ML servis

→

Python · FastAPI
POST /predict
letterbox priprema slike
`onnxruntime` + ResNet50.onnx

PostgreSQL
upisuje ASP.NET:
tabela `BeeHealthChecks`
istorija pregleda košnice

Sloj	Tehnologija
Trening	PyTorch + torchvision, Apple MPS
Format modela	ONNX (izvoz iz PyTorch-a)
ML servis	FastAPI + uvicorn + onnxruntime
Veza .NET → Python	typed `HttpClient`, multipart/form-data, JSON
Adresa servisa	`ML_SERVICE_URL` / appsettings
Baza	EF Core migracija, kolona `jsonb`
Slike	LocalStorageService → `wwwroot/uploads`

Odgovor ML servisa:

```
{
  "label": "varoa",
  "confidence": 0.9886,
  "all_probs": {"zdrava": 0.0114, "varoa": 0.9886},
  "model_version": "bee_health"
}
```

Servis proveren na svih 3.408 test slika: 0 razlika u odnosu na PyTorch model. Servis nedostupan → backend vraća 503, slika se ne čuva.

Ograničenja i sledeći koraci

Ograničenja

- trening skup: jedna kamera, siva podloga
- dve klase — zdrava / varoa
- vidljiva grinja ≠ zaražena košnica
- jedno seme po modelu
- malo terenskih fotografija

Sledeći koraci

- **terenski test skup** (20–40 fotografija, različite pozadine)
- **kalibracija praga** odluke (bez ponovnog treninga)
- po potrebi: BeeDataset u trening, zamena pozadine
- detekcija grinja (YOLO) — koordinate već postoje
- automatski predlog intervencije „Tretman“

Hvala

Pitanja?

Kod, notebook-ovi i izveštaj: github.com/MedzidJasarovic/KosnicaML